

MAT-032: Estadísticas de resumen

Felipe Osorio

`fosorios.mat.utfsm.cl`

Departamento de Matemática, UTFSM



Desde 1988 el SIMCE evalúa los **resultados de aprendizaje** de los estudiantes del sistema de educación chileno.

Objetivos:

- ▶ Describir el **comportamiento del aprendizaje** de los estudiantes.
- ▶ Determinar si existe diferencias significativas entre el **tipo de dependencia** (municipal, subvencionado, particular).

Características del problema:

- ▶ Mediciones de un mismo individuo (estudiante) **a través del tiempo** (4º y 8º básico, 2º medio).¹
- ▶ Datos disponibles para los años 2007, 2011 y 2013, pruebas de Lenguaje y Matemáticas.
- ▶ Aproximadamente **133K estudiantes** para ser analizados (base de datos de **mediano porte**).

¹ Conocido como: **datos con estructura longitudinal**.






Figura: histograma puntajes matemática.

²colegios, 1: municipales, 2: subvencionados y 3: particulares.




Figura: densidad puntajes matemática, organizados por Sexo.




Figura: densidad puntajes lenguaje, organizados por Sexo.



Datos del SIMCE

Base de datos con aproximadamente 133K individuos

> SIMCE

	Sex	type	math04	math08	math10	spa04	spa08	spa10
1	Male	1	338.86	303.94	372.51	342.74	327.92	317.38
2	Female	2	301.98	256.04	324.65	298.30	263.12	322.40
3	Female	1	258.45	263.44	225.95	192.59	206.72	216.66
4	Male	2	233.13	323.76	288.60	268.91	274.84	251.44
5	Male	1	284.17	276.37	293.11	236.55	261.67	283.78
6	Male	1	248.64	259.76	210.17	254.34	252.15	280.53

...

132947	Female	2	211.78	254.21	246.78	244.97	286.21	269.24
132948	Female	3	285.18	315.25	354.90	303.95	341.67	315.81
132949	Male	1	259.05	232.65	224.18	305.65	195.92	217.71



Para pensar:

- ▶ ¿Cómo resumir la información del total de 133K datos para cada una de las 8 variables?³
- ▶ ¿Podemos usar, digamos unas pocas cantidades para describir esta información?

³ Es decir un poco más de 1 millón de registros.



Lenna y algunas distorsiones de Lenna



(a) Original image




(b) Mean shift



(c) Salt-pepper noise



(d) Speckle noise



(e) Blurring



(f) Compression

Similaridad entre imágenes

- ▶ Existen diversos enfoques para estudiar la **similitud** entre dos **señales**, **imágenes** o (en general) **procesos**.
- ▶ El objetivo de la evaluación de la calidad de una imagen busca representar la **percepción de la calidad del ojo humano**.
- ▶ Se ha diseñado índices para estudiar el desempeño de algoritmos para problemas como: **compresión** o **restauración** de imágenes, entre otros. **Algoritmos de referencia completa** requieren de imágenes **distorsionadas** y de **referencia**.
- ▶ Se desea un **coeficiente apropiado** que combine la **luminosidad**, **contraste** y **estructura** (correlación) entre las imágenes. Este tipo de coeficientes son llamados **índice de similitud estructural (SSIM)**.



Structural Similarity Index (SSIM)

Definición (Wang et al., 2004):⁴

Sean \mathbf{x}, \mathbf{y} dos imágenes. El índice SSIM es definido como

$$\text{SSIM}(\mathbf{x}, \mathbf{y}) = l(\mathbf{x}, \mathbf{y})^\alpha \cdot c(\mathbf{x}, \mathbf{y})^\beta \cdot s(\mathbf{x}, \mathbf{y})^\gamma,$$

donde α, β y γ son parámetros no negativos,

$$l(\mathbf{x}, \mathbf{y}) = \frac{2 \bar{x} \bar{y} + c_1}{\bar{x}^2 + \bar{y}^2 + c_1}, \quad c(\mathbf{x}, \mathbf{y}) = \frac{2 s_x s_y + c_2}{s_x^2 + s_y^2 + c_2},$$
$$s(\mathbf{x}, \mathbf{y}) = \frac{s_{xy} + c_3}{s_x s_y + c_3},$$

$\bar{x}, \bar{y}, s_x^2, s_y^2$ y s_{xy} representan los promedios muestrales, varianzas y covarianza de \mathbf{x} y \mathbf{y} .

Las constantes c_1, c_2 y c_3 garantizan la estabilidad cuando denominadores son cercanos a cero.

⁴IEEE Transactions on Image Processing **13**, 600-612.



¿Cómo lucen los datos de Lenna?⁵

Lenna (original):

$$\begin{pmatrix} 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 153 & 152 & 153 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Lenna (sal y pimienta 10% contaminación):

$$\begin{pmatrix} 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 30 & 152 & 153 & \dots \\ 153 & 153 & 153 & 152 & 153 & \dots \\ 153 & 153 & 62 & 152 & 153 & \dots \\ 66 & 153 & 153 & 152 & 153 & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

⁵Imágenes $512 \times 512 = 262\,144$ observaciones.



Lenna y algunas distorsiones de Lenna⁶



(a) Original image




(b) Mean shift



(c) Salt-pepper noise



(d) Speckle noise



(e) Blurring



(f) Compression

⁶SSIM: (a) 1.000, (b) 0.989, (c) 0.649, (d) 0.441, (e) 0.346 y (f) 0.288.

Definición 1:

Considere una secuencia de números a_1, a_2, \dots, a_n . Se define la **sumatoria** de esta secuencia, como:

$$\sum_{i=1}^n a_i = a_1 + a_2 + \dots + a_n, \quad (1)$$

donde i denota el índice de la sumatoria, mientras a_i representa un elemento genérico. En este caso, n indica la cantidad de elementos que se están sumando.

Observación:

Es posible apreciar que la suma en (1) puede ser escrita de manera análoga como

$$\sum_{1 \leq i \leq n} a_i = a_1 + a_2 + \dots + a_n. \quad (2)$$

Además, si $n = 0$ el valor de la sumatoria se define como cero.



Preliminares: Sumas y productos

Sea R un conjunto de índices. Basta considerar el conjunto $R = \{1, 2, \dots, n\}$, para re-escribir la suma en (2) como:

$$\sum_{i \in R} a_i = a_1 + a_2 + \dots + a_n. \quad (3)$$

Observación:

Frecuentemente la notación dada en la Ecuación (3) es utilizada para sumas finitas, esta puede ser adaptada con facilidad para sumas infinitas. Por ejemplo,

$$\sum_{i=1}^{\infty} a_i = \sum_{i \geq 1} a_i = a_1 + a_2 + \dots .$$

Más formalmente, escribimos

$$\sum_{i=1}^{\infty} a_i = \lim_{n \rightarrow \infty} \sum_{i=1}^n a_i.$$



Resultado 1:

Sea a un número real. De este modo,

$$\sum_{i=1}^n a = \underbrace{a + a + \cdots + a}_{n \text{ términos}} = na.$$

En general, para $r < n$ tenemos

$$\sum_{i=r}^n a = (n - r + 1) a, \quad a \in \mathbb{R}.$$



Resultado 2:

Considere la secuencia x_1, x_2, \dots, x_n y sea a una constante. Entonces,

$$\begin{aligned}\sum_{i=1}^n a x_i &= a x_1 + a x_2 + \cdots + a x_n = a(x_1 + x_2 + \cdots + x_n) \\ &= a \sum_{i=1}^n x_i.\end{aligned}$$

En general, sean x_1, x_2, \dots, x_n y y_1, y_2, \dots, y_n dos secuencias de números y $a, b \in \mathbb{R}$. Entonces,

$$\sum_{i=1}^n (a x_i + b y_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i.$$



Preliminares: Sumas y productos

Note también que las sumatorias pueden ser **descompuestas** en varias sumas. En efecto, para una secuencia de números a_1, a_2, \dots, a_n . Tenemos que

$$\sum_{i=1}^n a_i = \sum_{i=1}^k a_i + \sum_{i=k+1}^n a_i, \quad k < n.$$

En general, sea $R = R_1 \cup R_2$, tal que $R_1 \cap R_2 = \emptyset$. Entonces,

$$\sum_{i \in R} a_i = \sum_{i \in R_1} a_i + \sum_{i \in R_2} a_i.$$



Ejemplo (propiedad telescópica):

Considere a_0, a_1, \dots, a_n una secuencia de números reales, y considere

$$\begin{aligned}\sum_{i=1}^n (a_i - a_{i-1}) &= (a_1 - a_0) + (a_2 - a_1) + \cdots + (a_{n-1} - a_{n-2}) + (a_n - a_{n-1}) \\ &= -a_0 + (a_1 - a_1) + \cdots + (a_{n-1} - a_{n-1}) + a_n \\ &= a_n - a_0.\end{aligned}$$

Ejemplo (Suma de una progresión geométrica):

Asuma que $x \neq 1$ y $n \geq 0$. Entonces,

$$a + ax + ax^2 + \cdots + ax^n = \sum_{j=0}^n ax^j = a \left(\frac{1 - x^{n+1}}{1 - x} \right).$$



Preliminares: Sumas y productos

Las siguientes son igualdades que **no satisface** la suma:

- ▶ Sean a_1, \dots, a_n y b_1, \dots, b_n dos secuencias de números reales. Entonces,⁷

$$\sum_{i=1}^n a_i b_i \neq \left(\sum_{i=1}^n a_i \right) \left(\sum_{i=1}^n b_i \right). \quad (4)$$

- ▶ Un caso particular del anterior es

$$\sum_{i=1}^n x_i^2 \neq \left(\sum_{i=1}^n x_i \right)^2.$$

- ▶ En general, si $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función no lineal. Entonces

$$\sum_{i=1}^n f(x_i) \neq f\left(\sum_{i=1}^n x_i\right).$$

⁷Basta notar que la cantidad de términos involucrados en cada uno de los lados de la ecuación anterior es diferente.



Preliminares: Sumas y productos

En ocasiones disponemos de secuencias números indexados mediante dos (o más) índices, es decir $\{a_{ij}\}$ para $i = 1, \dots, m; j = 1, \dots, n$. Suponga que deseamos sumar todos los elementos del conjunto $\{a_{ij}\}$. Es decir,

$$\sum_{i=1}^m \sum_{j=1}^n a_{ij} = a_{11} + \dots + a_{1n} + \dots + a_{m1} + \dots + a_{mn}.$$

Notamos fácilmente que podemos intercambiar el orden de las sumas. En efecto,

$$\sum_{i=1}^m \sum_{j=1}^n a_{ij} = \sum_{j=1}^n \sum_{i=1}^m a_{ij}$$

Observación:

Se debe resaltar que la operación de intercambiar el orden de las sumas **no** siempre es válido para series infinitas.



Preliminares: Sumas y productos

Retomando el resultado de la Ecuación (4), es válido considerar

$$\left(\sum_{i=1}^m a_i\right)\left(\sum_{j=1}^n b_j\right) = \sum_{i=1}^m \sum_{j=1}^n a_i b_j,$$

para comprender mejor esta ecuación, considere un caso especial

$$\begin{aligned}\left(\sum_{i=1}^2 a_i\right)\left(\sum_{j=1}^3 b_j\right) &= (a_1 + a_2)(b_1 + b_2 + b_3) \\ &= (a_1 b_1 + a_1 b_2 + a_1 b_3) + (a_2 b_1 + a_2 b_2 + a_2 b_3) \\ &= \sum_{i=1}^2 \left(\sum_{j=1}^3 a_i b_j\right).\end{aligned}$$

Asimismo,

$$\left(\sum_{i=1}^n x_i\right)^2 = \left(\sum_{i=1}^n x_i\right)\left(\sum_{j=1}^n x_j\right) = \sum_{i=1}^n \sum_{j=1}^n x_i x_j.$$



Ejemplo:

Otras sumas útiles (que pueden ser probadas usando inducción) son:

$$\sum_{k=1}^n k = 1 + 2 + \cdots + n = \frac{n(n+1)}{2}.$$

$$\sum_{k=1}^n k^2 = 1^2 + 2^2 + \cdots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$



Existe una notación análoga para productos. Considere la siguiente definición

Definición 2:

Sea a_1, a_2, \dots, a_n una secuencia de números. Se define la **productoria** de esta secuencia, como:

$$\prod_{i=1}^n a_i = a_1 \cdot a_2 \cdots a_n.$$

En general, podemos escribir

$$\prod_{i \in R} a_i,$$

donde R representa un conjunto de índices. Note que si no existe algún entero $i \in R$, el producto se define con el valor uno.



Ejemplo (factorial de un número):

Un ejemplo del uso de productorios es:

$$1 \cdot 2 \cdot 3 \cdots (n-1) \cdot n = \prod_{j=1}^n j = n!$$

que se denomina *n factorial*. Evidentemente,

$$n! = (n-1)! \cdot n.$$

Recuerde que $0!$ por definición es 1 .⁸

⁸Para $n = 1$, tenemos $1! = 0! \cdot 1 \implies 0! = 1!/1 = 1$.



Ingredientes:

Conjunto de n observaciones $\{x_1, x_2, \dots, x_n\}$ conocidas como **muestra**.

En general, nuestro interés recaerá en resúmenes de la información a través de una **estadística**, digamos $T = T(x_1, \dots, x_n)$.

En esta clase consideraremos 3 tipos de **estadísticas de resumen**⁹ para una muestra $\mathbf{x} = (x_1, \dots, x_n)^\top$,

- ▶ medidas de posición.
- ▶ medidas de dispersión.
- ▶ medidas de forma (asimetría y curtosis).

⁹En ocasiones escribiremos $T = T(\mathbf{x})$.



Definición 3 (Media muestral o promedio):

Sea x_1, \dots, x_n valores muestrales. Se define el **promedio** o **media muestral** como:

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i.$$

Suponga que la observación i -ésima, digamos x_i , se repite n_i veces. Entonces tenemos

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n n_i x_i = \sum_{i=1}^n f_i x_i,$$

donde $f_i = n_i/n$ es la frecuencia relativa. En general, considere “pesos” $\omega_1, \dots, \omega_n$ asociados a las observaciones x_1, \dots, x_n . En este caso,

$$\bar{x} = \frac{1}{\sum_{j=1}^n \omega_j} \sum_{i=1}^n \omega_i x_i.$$



Ejemplo:

Considere el conjunto de datos $x = \{1, 2, 2, 2, 3, 3, 8\}$. Tenemos $n = 7$, y

$$\begin{aligned}\sum_{i=1}^7 x_i &= 1 + 2 + 2 + 2 + 3 + 3 + 8 \\ &= 1 + 2 \cdot 3 + 2 \cdot 3 + 8 = 21,\end{aligned}$$

así $\bar{x} = 21/7 = 3$. Note también que el gráfico de **tallo y hoja**, adopta la forma:

1		*		
2		*	*	*
3		*	*	
4				
5				
6				
7				
8		*		



Ejemplo (datos de accidentes):

Suponga el siguiente conjunto de datos:

Número de accidentes (x_i)	Frecuencia (n_i)	$n_i x_i$
0	55	0
1	14	14
2	5	10
3	2	6
4	0	0
Total	76	30

De este modo, $\bar{x} = 30/76 = 0.3947$ es el número promedio de accidentes.

Definición 4 (Estadísticos de orden):

Sea x_1, \dots, x_n una muestra. Entonces los valores ordenados

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)},$$

se denominan **estadísticos de orden**. Algunas estadísticas de orden son: el **mínimo** muestral $x_{(1)}$, el **máximo** muestral $x_{(n)}$.

Definición 5 (Mediana):

Sea $x_{(1)}, \dots, x_{(n)}$ observaciones ordenadas. La **mediana** es definida como:

$$\text{me}(\mathbf{x}) = \begin{cases} x_{(n+1)/2}, & n \text{ es impar,} \\ (x_{(n/2)} + x_{(n/2+1)})/2, & n \text{ es par.} \end{cases}$$



Observación:

Sea $f(x)$ cualquier función de números reales.¹⁰ Entonces podemos definir

$$\bar{f} = \frac{1}{n} \sum_{i=1}^n f(x_i) = \frac{1}{n} (f(x_1) + \cdots + f(x_n)).$$

Caso particular (media geométrica):

Suponga x_1, \dots, x_n números positivos y $f(x) = \log(x)$. Entonces la **media geométrica** G es dada por:

$$\log G = \frac{1}{n} (\log x_1 + \cdots + \log x_n) = \frac{1}{n} \sum_{i=1}^n \log x_i.$$

Es decir,

$$G = (x_1 \cdot x_2 \cdots x_n)^{1/n} = \left(\prod_{i=1}^n x_i \right)^{1/n}.$$

¹⁰Por ejemplo, $f(x) = x^2$ lleva a la media cuadrática, mientras que $f(x) = 1/x$ es la media armónica.

Datos del SIMCE: Puntajes de matemáticas

```
## sólo puntajes de matemáticas
> MATH
math04 math08 math10
1 338.86 303.94 372.51
2 301.98 256.04 324.65
3 258.45 263.44 225.95
4 233.13 323.76 288.60
5 284.17 276.37 293.11
6 248.64 259.76 210.17
...

> x <- MATH$math04 # análogamente x <- MATH[,1]
> mean(x)          # promedio
[1] 261.5766
> median(x)        # mediana
[1] 263.96
> library(fastmatrix) # https://faosorios.github.io/fastmatrix
> geommean(x)       # media geométrica
[1] 256.0357
# alternatively: exp(mean(log(x)))

> apply(MATH, 2, mean) # para todas la variables
math04 math08 math10
261.5766 269.6779 276.6267
```



Medidas de dispersión

Considere los siguientes conjuntos de datos:

$$D_1 = \{10, 20, 30\}, \quad D_2 = \{5, 5, 20, 35, 35\}, \quad D_3 = \{20, 20, 20\},$$

Tenemos los gráficos de tallo-y-hoja:

Datos D_1 :

5	
10	*
15	
20	*
25	
30	*
35	

Datos D_2 :

5	*	*
10		
15		
20	*	
25		
30		
35	*	*

Datos D_3 :

5			
10			
15			
20	*	*	*
25			
30			
35			



Sea \bar{x}_j y me_j el promedio y la mediana asociada al conjunto de datos D_j ($j = 1, 2, 3$). Entonces,

$$\bar{x}_1 = \frac{1}{3}(10 + 20 + 30) = \frac{60}{3} = 20,$$

$$\bar{x}_2 = \frac{1}{5}(2 \cdot 5 + 20 + 2 \cdot 35) = \frac{100}{5} = 20,$$

$$\bar{x}_3 = \frac{3 \cdot 20}{3} = 20.$$

Además, $me_j = 20$ para todo j .

Observación:

Es decir, tenemos tres configuraciones de datos con **valores centrales idénticos**.



Sean Q_1 y Q_3 las medianas de la mitad inferior y superior de los datos, conocidos como el 1er y 3er **cuartiles**, respectivamente. Esto permite definir:

$$IQR = Q_3 - Q_1,$$

que es conocido como **rango intercuartílico**.

También podemos considerar el **rango** de la muestra como:

$$R = \max\{x_i\}_{i=1}^n - \min\{x_i\}_{i=1}^n = x_{(n)} - x_{(1)}.$$

Algunos software estadísticos (R/S-Plus, Stata, entre otros) reportan:

$$x_{(1)}, Q_1, \text{me}, Q_3, x_{(n)}.$$



Medidas de dispersión

Considere subdividir los datos ordenados $x_{(1)}, \dots, x_{(n)}$ en secciones de 100%, llamados **percentiles**. Entonces el percentil de orden j ($1 \leq j \leq 100$) está dado por:

$$P_j = x_{(j(n+1)/100)}.$$

Note que $Q_1 = P_{25}$, la mediana (o 2º cuartil, Q_2) es $me = P_{50}$ y $Q_3 = P_{75}$.

Ejemplo:

Considere el conjunto de datos $x = \{4, 7, 18, 1, 7, 13, 2\}$ y suponga que deseamos calcular el rango intercuartílico IQR .

Primeramente es necesario ordenar el conjunto de datos:

$$\{x_{(1)}, x_{(2)}, x_{(3)}, x_{(4)}, x_{(5)}, x_{(6)}, x_{(7)}\} = \{1, 2, 4, 7, 7, 13, 18\}.$$

Disponemos de $n = 7$ datos, luego para obtener el 1er y 3er cuartiles podemos usar

$$Q_1 = P_{25} = x_{(25 \cdot (7+1)/100)} = x_{(1.8/4)} = x_{(2)} = 2,$$

$$Q_3 = P_{75} = x_{(75 \cdot (7+1)/100)} = x_{(3.8/4)} = x_{(6)} = 13.$$

De este modo, $IQR = Q_3 - Q_1 = 13 - 2 = 11$.



Definición 6 (Varianza muestral):

Considere x_1, \dots, x_n valores observados, se define su **varianza muestral** como:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Observación:

$s = \sqrt{s^2}$ se denomina **desviación estándar**.



Observación:

Otras medidas de dispersión:

- Desviación absoluta en torno de la media:

$$\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|.$$

- Desviación absoluta en torno de la mediana:

$$\frac{1}{n} \sum_{i=1}^n |x_i - \text{me}(\mathbf{x})|.$$

- r -ésimo momento centrado en torno de a :¹¹

$$m_r(a) = \frac{1}{n} \sum_{i=1}^n (x_i - a)^r.$$

¹¹Para $r = 2$ y $a = \bar{x}$ obtenemos la varianza.

Propiedades:

(a)

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

(b)

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$$

(c) \bar{x} es el valor que minimiza la función:

$$S(a) = \sum_{i=1}^n (x_i - a)^2.$$

(d) Sea x_1, \dots, x_n y considere la transformación:

$$y_i = a x_i + b, \quad i = 1, \dots, n.$$

Entonces $\bar{y} = a\bar{x} + b$ y $s_y^2 = a^2 s_x^2$.



Propiedades del promedio y varianza muestrales

(a) En efecto,

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} = \sum_{i=1}^n x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0.$$

(b) (Fórmula de Köning)

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x})^2 &= \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \sum_{i=1}^n x_i^2 - 2\bar{x} \sum_{i=1}^n x_i + n\bar{x}^2 \\ &= \sum_{i=1}^n x_i^2 - n\bar{x}^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2\end{aligned}$$



Propiedades del promedio y varianza muestrales

(c) \bar{x} es el valor que minimiza la función $S(a) = \sum_{i=1}^n (x_i - a)^2$. En efecto, note que

$$\frac{d}{da} S(a) = \sum_{i=1}^n \frac{d}{da} (x_i - a)^2 = -2 \sum_{i=1}^n (x_i - a),$$

resolviendo la condición de primer orden, tenemos

$$\sum_{i=1}^n (x_i - \hat{a}) = 0,$$

desde donde sigue que $\hat{a} = \bar{x}$. Además

$$\frac{d^2}{da^2} S(a) = -2 \sum_{i=1}^n \frac{d}{da} (x_i - a) = 2n,$$

y como la segunda derivada es positiva (para cualquier valor de n), obtenemos que \bar{x} es máximo global.



Propiedades del promedio y varianza muestrales

- (d) Sea x_1, \dots, x_n y considere la transformación, $y_i = ax_i + b$, para $i = 1, \dots, n$.
Entonces

$$\begin{aligned}\bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \sum_{i=1}^n (ax_i + b) = \frac{1}{n} \left(a \sum_{i=1}^n x_i + b \right) \\ &= a \left(\frac{1}{n} \sum_{i=1}^n x_i \right) + b = a\bar{x} + b.\end{aligned}$$

Mientras que

$$s_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2,$$

como $y_i - \bar{y} = ax_i + b - (a\bar{x} + b) = a(x_i - \bar{x})$, sigue que

$$\begin{aligned}s_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n-1} \sum_{i=1}^n \{a(x_i - \bar{x})\}^2 \\ &= a^2 \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = a^2 s_x^2.\end{aligned}$$



Observación:

Un caso particular de importancia es la **estandarización** del conjunto de datos x_1, \dots, x_n , definida como:

$$z_i = \frac{x_i - \bar{x}}{s}, \quad i = 1, \dots, n.$$

Entonces,¹²

$$\bar{z} = 0 \quad \text{y} \quad s_z^2 = 1.$$

¹²Basta hacer $a = 1/s$ y $b = \bar{x}/s$ en la Propiedad (d).

Definición 7 (Coeficiente de variación):

Este coeficiente es una medida que compara la desviación estándar con el promedio de una muestra y es definido como

$$CV = s/\bar{x}, \quad \bar{x} \neq 0.$$

El coeficiente es particularmente útil para **comparar dos o más muestras** (o grupos).


Observación:

Un valor pequeño para el CV está asociado a una muestra homogénea.


Observación:

En Econometría $1/CV$ es conocido como la **razón de Sharpe**.





(a) distribuciones simétricas



(b) asimetría negativa (—), positiva (---)

Definición 8 (Coeficiente de asimetría):

Considere m_3 el tercer momento muestral, entonces se define el **coeficiente de asimetría** (o sesgo) como:

$$b_1 = \frac{m_3}{s^3} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3.$$

Observación:


- ▶ Si $b_1 = 0$ la distribución es simétrica con relación a \bar{x} .
- ▶ Si $b_1 > 0$ la distribución tiene **sesgo positivo**. En caso contrario, decimos que tiene **sesgo negativo**.

Observación:

Se han definido diversos índices de simetría, por ejemplo la **medida de sesgo de Galton**:

$$b_G = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1}.$$





(a) Distribución leptocúrtica ($- \cdot -$), mesocúrtica ($—$) y platicúrtica ($- -$)

Definición 9 (Coeficiente de curtosis):

Considere m_4 el cuarto momento muestral, entonces se define el **coeficiente de curtosis**¹³ como:

$$b_2 = \frac{m_4}{s^4} - 3 = \left\{ \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 \right\} - 3.$$

Observación:

El término -3 hace que $b_2 = 0$ cuando los datos siguen una **distribución normal**.

¹³también conocido como **exceso de curtosis**

Datos del SIMCE: Puntajes de matemáticas¹⁴

```
> z <- quantile(x)
> z
      0%      25%      50%      75%     100%
 87.74 226.32 263.96 299.29 369.55

> sd(x) # desviación estándar
[1] 51.79042
> var(x) # varianza
[1] 2682.247

> library(fastmatrix) # https://faosorios.github.io/fastmatrix
> moments(x)
$second
[1] 2682.227
$third
[1] -30409.6
$fourth
[1] 18784749
$skewness
[1] -0.2189084
$kurtosis
[1] -0.3889947
```

¹⁴ $n = 132\,793$ observaciones, así que $(n-1)/n = 0.9999925$.



Gráfico de cajón con bigotes (boxplot)

